Reducción Dimensionalidad
vía
Análisis de Componentes Principales
(PCA)

Prof. Nibaldo Rodríguez Agurto

Análisis de Componentes Principales: PCA

- Su objetivo es la reducción de la dimensionalidad de un conjunto de datos minimizando la pérdida de información.
- Transforma un conjunto de variables potencialmente correlacionadas en un nuevo conjunto de variables no-correlacionadas.



- N: Números de muestras.
- D: número de variables explicativas.
- d: dimensión de nuevas variables explicativas.

Reducción Dimensionalidad: PCA-SVD

- Considerar un *dataset* de ***N***-muestras con ***D***-variables explicativas, la cual es dada como:

$$X \in \Re^{(N \times D)}$$

***STEP #1*: Centrar en media el *dataset* *X*.**

$$x = X(:, i), \qquad i = 1,2, \dots, D$$

$$\mu_x = \text{mean(x)}$$

$$X(:, i) = X(:, i) - \mu_x$$

Reducción Dimensionalidad: Lineal vía SVD

STEP #2: Normalizar el *dataset X*.

$$Y = \frac{X}{\sqrt{N-1}}$$

$$Y \in \Re^{(N \times D)}$$

Reducción Dimensionalidad: Lineal vía SVD

STEP # 3: Descomposición de Valores Singulares de *Y*.

$$[U \ S \ \mathrm{V}] = \mathrm{SVD(Y)}$$

U : **Matriz ortogonal derecha de vectores singulares.** S : **Matriz diagonal de valores singulares.**

V : **Matriz ortogonal izquierda de vectores singulares.**

- Cada vector propio define la orientación de un nuevo eje coordinada.
- Cada vector propio es ortonormal, lo cual implica eliminar la multicolinealidad.
- Cada valor propio denota estadísticamente la cantidad de varianza (información) que preserva el eje definido por su vector propio.
- La suma de todos lo valores propios es igual a la suma de la varianza del *dataset* original.
- Los valores propios permiten calcular la proporción de varianza explicada por cada nuevo eje de orientación , dado como:

$$VE(\%) = \frac{\lambda_i}{\sum_{k=1}^{D} \lambda_k} 100, \quad s_i = \sqrt{\lambda_i}$$

Reducción Dimensionalidad: Lineal vía SVD

STEP #4: Componentes Principales (PC):

- Seleccionar los *d*-valores singulares mayores.

$$Z = X \times V(:, 1:d)$$

- **Nuevas variables proyectadas**
- **Nuevos ejes (direcciones)**

$$Z \in \Re^{(N \times d)}$$

- **El primer PC (PC_1) : es la nueva variable que tiene la mayor varianza.**
- **El segundo PC (PC_2) : posee la segunda mayor varianza.**
- **El PC_i: posee la i-ésima mayor varianza y así sucesivamente.**

Ejemplo #1: Reducción Diemensionalidad: SVD

- Considerar el siguiente *dataset*:

$$X = \begin{bmatrix} 3.7347 & 4.0543 & 1.6266 & 6.0207 & 9.2184 & 8.1036 \\ 5.6098 & 2.1635 & 3.1388 & 2.0036 & 7.0827 & 5.7767 \\ 0.7621 & 0.6441 & 7.7590 & 8.0348 & 5.7052 & 9.8035 \\ 7.0696 & 2.4982 & 9.5548 & 2.9519 & 1.8949 & 9.8666 \\ 2.0026 & 0.1496 & 7.3536 & 6.2660 & 1.9766 & 5.2805 \\ 0.1178 & 6.5878 & 8.3876 & 4.2613 & 4.2601 & 3.3974 \\ 0.0835 & 3.8930 & 1.0034 & 3.6575 & 8.2480 & 5.0692 \\ 3.2631 & 7.2786 & 1.1642 & 8.2578 & 3.2100 & 6.7618 \end{bmatrix}$$

- ***Solución:***

Data Normalizada:

$$\mathbf{Y} = \begin{bmatrix} 0.3418 & 0.2440 & -1.2745 & 0.3171 & 1.5190 & 0.5088 \\ 1.0505 & -0.4706 & -0.7029 & -1.2012 & 0.7118 & -0.3707 \\ -0.7817 & -1.0449 & 1.0434 & 1.0784 & 0.1912 & 1.1513 \\ 1.6023 & -0.3441 & 1.7221 & -0.8428 & -1.2490 & 1.1752 \\ -0.3129 & -1.2318 & 0.8902 & 0.4098 & -1.2182 & -0.5582 \\ -1.0253 & 1.2016 & 1.2810 & -0.3479 & -0.3551 & -1.2700 \\ -1.0382 & 0.1831 & -1.5100 & -0.5761 & 1.1522 & -0.6381 \\ 0.1635 & 1.4627 & -1.4492 & 1.1627 & -0.7520 & 0.0016 \end{bmatrix}$$

Ejemplo #1: Reducción Diemnsionalidad: SVD

- ***Solución:*** [U S V]=svd(Y)

Valores Singulares = diag(S)=

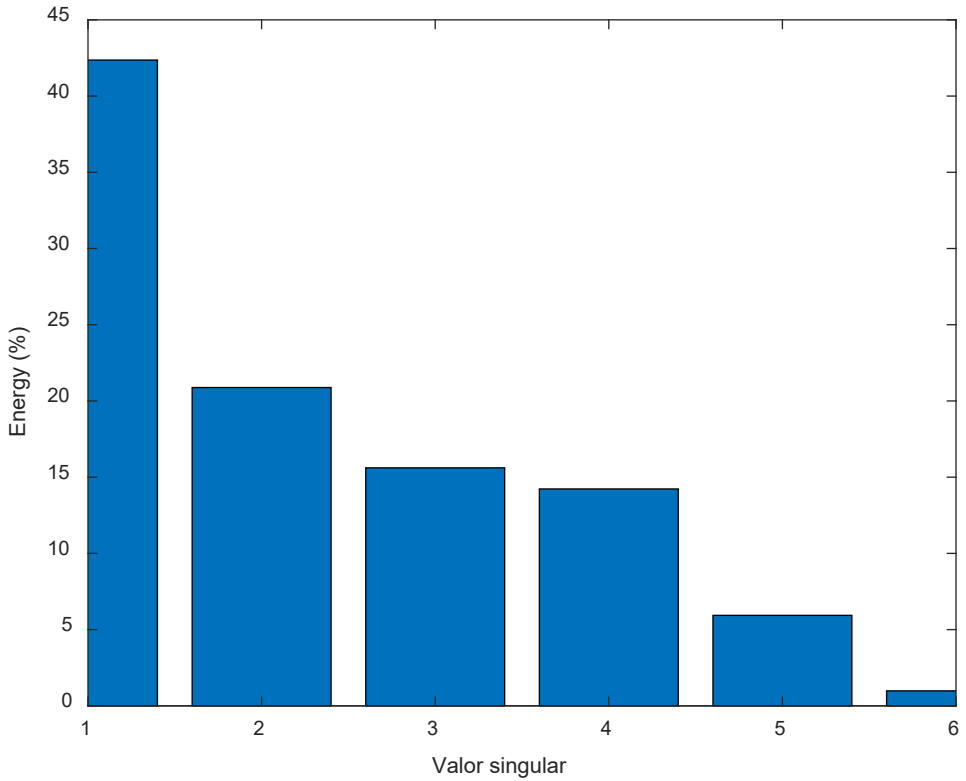
$$s = [4.3662 \quad 3.0654 \quad 2.6507 \quad 2.5303 \quad 1.6343 \quad 0.6649]$$

V=[-0.1612 -0.6762 0.3152 -0.4005 -0.1009 -0.4969
0.2919 0.3390 0.3814 -0.5556 0.5878 0.0145
-0.7790 0.2138 0.0684 0.2408 0.4537 -0.2811
0.0251 0.2945 -0.6961 -0.3988 -0.0950 -0.5099
0.4959 -0.2762 -0.1650 0.4973 0.4997 -0.3919
-0.1884 -0.4681 -0.4885 -0.2581 0.4240 0.5102]

Ejemplo #1: Reducción Diemnsionalidad: SVD

- ***Solución:*** **Energía de valores singulares (%)**

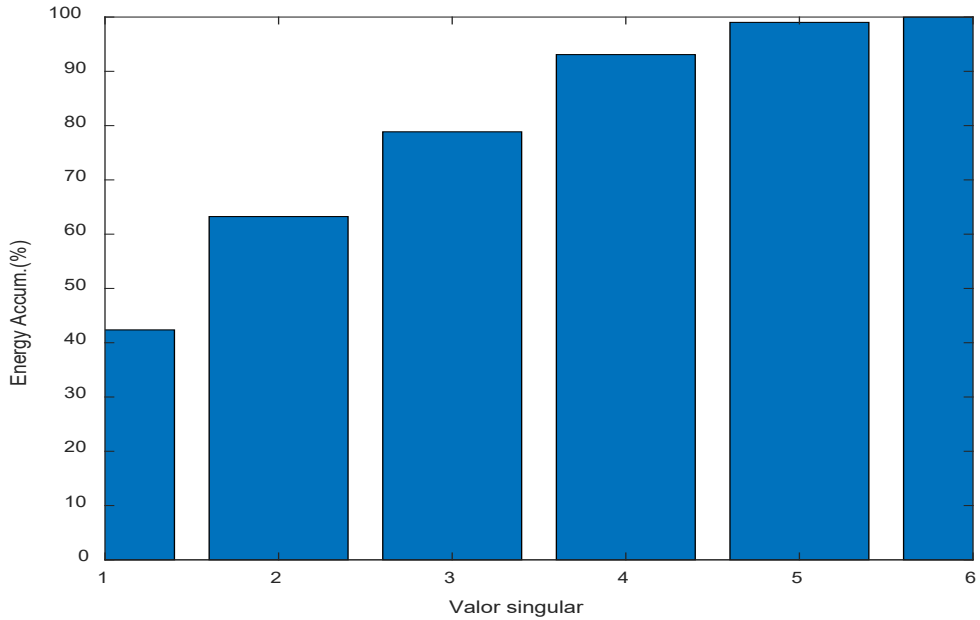
$$E = \frac{s_i^2}{\sum_j^D s_j^2}$$



Ejemplo: Reducción Diemnsionalidad: SVD

- ***Solución:*** **Criterio de Selección de *d*: Energía Acumulada(%)**

$$Accum = \sum_{i=1}^{j} E_{i,} \quad j=1,2,\cdots,D$$



Ejemplo: Reducción Diemnsionalidad: SVD

- ***Solución:*** **Criterio de Selección de *d*: Energía Acumulada(%)**

- Accum=[42.3620 63.2424 78.8556 93.0828 99.0177 100.0000]

- **Umbral de Selección**: $Accum \leq 95\%$

$$V_r = V(:, 1:r), \quad r = \textbf{4-columnas}$$

$\mathbf{V_r}$=[-0.1612 -0.6762 0.3152 -0.4005
0.2919 0.3390 0.3814 -0.5556
-0.7790 0.2138 0.0684 0.2408
0.0251 0.2945 -0.6961 -0.3988
0.4959 -0.2762 -0.1650 0.4973
-0.1884 -0.4681 -0.4885 -0.2581]

Ejemplo: Reducción Diemnsionalidad: SVD

- ***Solución:*** **Componentes Principales**

$$Z = X \cdot V_r$$

$$Z = \begin{bmatrix} 4.4296 & -2.6066 & -1.6041 & -0.2164 \\ 1.6761 & -3.6961 & 2.6548 & 1.5879 \\ -2.8755 & 0.3263 & -5.0752 & 1.3564 \\ -6.7786 & -3.4003 & 1.8793 & -1.6514 \\ -3.9452 & 1.8594 & -0.8445 & 1.0555 \\ -1.1307 & 5.1978 & 3.0265 & 0.9034 \\ 5.4877 & 0.6667 & 0.4284 & 2.4285 \\ 3.1366 & 1.6528 & -0.4652 & -5.4639 \end{bmatrix}$$

Reducción Dimensionalidad: No-Lineal PCA

Prof. Nibaldo Rodríguez Agurto

Reducción Dimensionalidad No-Lineal: PCA-RFF

- Análisis de Componentes Principales (PCA) vía
  - **Características de Fourier Aleatorias (RFF)**.

- Considerar un *dataset* de ***N***-muestras con ***D***-variables explicativas, la cual es dada como: $X \in \Re^{(N \times D)}$

***STEP # 1*: Normalización del *dataset* vía z-scores:**

$$x = X(:, i), \qquad i = 1,2, \ldots, D$$

$$\mu_x = \text{mean(x)}, \quad \sigma_x = std(x)$$

$$X(:, i) = \frac{(X(:, i) - \mu_x)}{\sigma_x}$$

Reducción Dimensionalidad No-Lineal: PCA-RFF

***STEP # 2*: Crear RFF como:**

$$W \in \mathcal{R}^{(D,d)}, \quad b \in \mathcal{R}^{d},$$

- ***W***: denota la matriz de frecuencias aleatorias con distribución normal dada por:

$$W_{i,j} \sim \mathcal{N}(0, 2\gamma)$$

- ***b***: vector de fase con distribución uniforme dada por:

$$b_j \sim U(0, 2\pi)$$

Reducción Dimensionalidad No-Lineal: PCA-RFF

STEP # 3: Crear Matriz de Características No-Lineales:

$$Z = \sqrt{\frac{2}{d}} cos(XW + b), \; Z \in \mathcal{R}^{(N,d)}$$

- ***d***: representa la nueva dimensión del espacio de característica de Fourier.

STEP # 4: Calcular PCA-SVD de Z

- Seleccionar los d_1-valores singulares mayores como:

$$V_r = PCA_{svd}(Z, d_1), \qquad X_r = ZV_r$$

Nueva Matriz de Características: $X_r \in \mathcal{R}^{(N,d_1)}$

Reducción Dimensionalidad No-Lineal: RFF + Mínimos Cuadrados Regularizados (RFF+RLS)

Prof. Nibaldo Rodríguez Agurto

Reducción Dimensionalidad No-Lineal: (RFF- RLS)

- Considerar un *dataset* de ***N***-muestras con ***D***-variables explicativas, la cual es dada como:

$$X \in \Re^{(N \times D)}$$

***STEP # 1*: Normalización del** dataset **X:**

- z-scores
- Otro método

Reducción Dimensionalidad No-Lineal: RFF-RLS

***STEP # 2*: Crear Matriz de RFF:**

$$Z = \sqrt{\frac{2}{d}} cos(XW + b),\ \mathrm{Z} \in \mathcal{R}^{(N,d)}$$

$$W_{i,j} \sim \mathcal{N}(0, 2\gamma) \qquad b_j \sim U(0, 2\pi)$$

***STEP # 3*: Calcular una Combinación Lineal de RFF:**

$$Y = ZW_D, \qquad Y \in \mathcal{R}^{(N,D)}$$

$W_D \in \mathcal{R}^{(d,D)}$ **: Matriz de Pesos (ponderación):**

Reducción Dimensionalidad No-Lineal: RFF-RLS

***STEP # 4*: Estimación de pesos W_D vía Regularized Least Squares (RLS)**

$$E = \frac{1}{2}\|X - Y\|_2^2 + \frac{\lambda}{2}\|W_D\|_2^2$$

$$\frac{\partial E}{\partial W_D} = \frac{\partial E}{\partial Y}\frac{\partial Y}{\partial W_D}$$

$$W_D = (Z^T Z + \lambda I_d)^{-1} Z^T X, \qquad W_D \in \mathcal{R}^{(d,D)}$$

Reducción Dimensionalidad No-Lineal: RFF-RLS

***STEP #5*: Calcular *dataset* reducido vía matriz de pesos W_D como:**

$$X_r = X[W_D]^T$$

$$W_D \in \mathcal{R}^{(d,D)}$$

$$X_r \in \mathcal{R}^{(N,d)}$$ **: Nuevo *dataset***

Reducción Dimensionalidad No-Lineal: usando Mínimos Cuadrados Separables (SLS)

Prof. Nibaldo Rodríguez Agurto

Reducción Dimensionalidad No-Lineal: (SLS)

- Considerar un *dataset* dado por: $\{(x_i)\}_{i=1}^{N}, x_i \in \Re^D$
- ***N***: número de muestras, ***D***: número de variables explicativas.

- Inspirado en los métodos:
  - (a) PCA
  - (b) RFF
  - (c) Mínimos Cuadrados Lineal/No-Lineal.

- *Representar* las Top-***J*** variables explicativas relevantes como:

$$z_j = v_{j,1}x_1 + v_{j,2}x_2 + \cdots + v_{j,D}\, x_D, \qquad j = 1,2,\cdots,J$$

Reducción Dimensionalidad No-Lineal: (SLS)

$$z_j = v_{j,1}x_1 + v_{j,2}x_2 + \cdots + v_{j,D}x_D, \qquad j = 1,2,\cdots,J$$

$$h_j = f(z_j), \quad f(\cdot) \coloneqq no\text{-lineal}$$

$$y_m = u_{m,1}h_1 + u_{m,2}h_2 + \cdots + u_{m,J}h_J, \qquad m = 1,2,\cdots,D$$

Reducción Dimensionalidad No-Lineal: SLS

- Usando notación matricial podemos re-escribir modelo híbrido como:

$$Z = X \times V, \qquad V \in \Re^{(D,J)}$$

$$H = f(Z), \qquad H \in \Re^{(N,J)}$$

$$Y = H \times U, \qquad U \in \Re^{(J,D)},$$

- ***V*: matriz de proyección para reducir la dimensionalidad (no-lineal).**
- ***U*: matriz de proyección para reducir la dimensionalidad (lineal).**
- ***K*: denota las Top-*d* variables explicativas relevantes.**

- ***Para Hallar la matriz V usamos el Método Mínimos Cuadrados Separables.***

Mínimos Cuadrados Separables (SLS)

- El método SLS está basado en dos etapas:
- ***Etapa #1:*** Estimar los parámetros lineales usando el método RLS.
- ***Etapa #2:*** Estimar los parámetros no-lineales usando el Descenso del Gradiente con Momentum (mGD) de la función de Costo.

- **Etapa #1:** Función de Costo: Suma Cuadrática Residual Penalizada:

$$E = \frac{1}{2}\|Y - X\|^2 + \frac{\lambda}{2}\|U\|^2, \qquad \lambda \in \Re$$

Donde $\|\cdot\|$ • **Representa la Norma Euclidiana**

- X: **Valor Deseado, el cual es dado por la data de entrada al modelo .**

Etapa #1: RSS-RLS

- ***Estimación de Pesos U usando el criterio de la primera derivada:***

$$\frac{\partial E}{\partial U} = \frac{\partial E}{\partial Y}\frac{\partial Y}{\partial U} = 0$$

$$U = \left(H^T H + \lambda I_J\right)^{-1} H^T X, \qquad U \in \mathcal{R}^{(J,D)}$$

Etapa #2: Estimación Matriz *V* vía *mDG*

$$E = \frac{1}{2N}\sum_{n=1}^{N} E_n$$

- **N: número de muestras**

$$E_n = \frac{1}{2}\sum_{m=1}^{D}\left(y_{n,m} - x_{n,m}\right)^2$$

- ***La estimación de pesos V usando el criterio de la primera derivada***

$$\frac{\partial E_n}{\partial V} = 0$$

$$\frac{\partial E_n}{\partial V} = \frac{\partial E_n}{\partial Y_n}\frac{\partial Y_n}{\partial V}$$

Etapa #2: Estimación Matriz *V* vía *Descenso del Gradiente*

- ***La estimación de matriz V es usando el criterio de la primera derivada***

$$\frac{\partial Y_n}{\partial V} = \frac{\partial Y_n}{\partial H_n}\frac{\partial H_n}{\partial V}$$

$$\frac{\partial E_n}{\partial V} = \{U^T \times (Y_n - X_n)\} \otimes H_n'(z) \times X_n^T$$

Descenso del Gradiente con Momentum (mGD)

- **Usando Notación Matricial:**

$$\frac{\partial E}{\partial V} = \{U^T \times (Y - X)\} \otimes H'(z) \times X^T$$

$$V^{(t)} = V^{(t-1)} - Q^{(t)}$$

- **Ajuste de Pesos No-Lineales**

$$Q^{(t)} = \beta \cdot Q^{(t-1)} + \mu \frac{\partial E}{\partial V}$$

$$Q^{(0)} = 0$$

$$t = 1, \dots, MaxIters, \qquad \mu \in (0,1), \beta = 0.9$$

Reducción Dimensionalidad No-Lineal: SLS

- **Calcular *dataset* reducido vía matriz de pesos V como:**

$$X_r = XV$$

$$V \in \mathcal{R}^{(D,J)}$$

$$X_r \in \mathcal{R}^{(N,J)}$$ **: Nuevo *dataset***

Descenso del Gradiente Estocástico vía MiniBatch

Prof. Nibaldo Rodríguez Agurto

Training: MiniBatch mGD

- Asuma un registro de datos correspondiente a *N*-muestras y D-*variables explicativas,* denotado *como:*

$$\{X_n\}_{n=1}^{N}, \quad X_n \in \Re^D,$$

- X_n : representa la *n*-ésima muestra de training.
- D : denota el número de variables explicativas.

Training: MiniBatch mGD

- **Paso #1**: Re-ordenar aleatoriamente la localización de cada muestra del ***dataset*** de training ***X***.

- **Paso #2**: Dividir las ***N***-muestras del *dataset* en **Batch** (bloques) de ***M***-muestras.

$$B = \frac{N}{M}$$

B : Número de Batch

- **Paso #3**: Ajustar los pesos del ***Modelo*** usando un Número Máximo de Épocas.
  - Cada Épocas ajusta los pesos del ***Modelo*** ***B***-veces vía el mGD.

Pseudo-code: Training MiniBatch mGD

```
Param=Set_Parameters()

For t=1 to MaxIter
        X= RandSort(X)
        Param= train_minibatch(X, Param)
        if mod(t,100)==0
                print('Iteración-MSE', t, Pram.MSEavg)
        endif

EndFor
```

Pseudo-Code: Training MiniBatch mGD

```
Function train_minibatch(X, Param)

nBatch= floor(Param.N/Param.BatchSize)

For n=1 to nBatch
        X=Get_Batch(n, Param.BatchSize,X)
        Param= Ajuste_Peso_lineal(X, Param)
        Param= Ajuste_Peso_Nolineal(X, Param)
EndFor

Param.MSEavg = mean(Param.MSE)

return(Param)
```

Clasificación Multi-Clases

Prof. Nibaldo Rodríguez Agurto

CONTINUARÁ….