Clasificación Multi-Clasea:
Regresión Softmax
+
Descenso del Gradiente (GD)
+
Descenso del Gradiente Estocástico (SGD)

Clasificación Multiclase: Regresión Softmax

- Considerar un problema de clasificación de ***K-*** clases.
- Cada muestra es caracterizada por *D*-atributos .

- El *dataset* para este problema es representado como:

  - **Data de entrada: *n*-ésima nuestras** $X_n \in \Re^D, n \in N$

  - **Etiquetas de las clases** $T_n \in \{1,2,\cdots,K\}$

- Para representar las etiquetas de cada clases es utilizada una codificación binaria:

  - **One-hot-encoder**:

Clasificación Multi-clases: Regresión Softmax

- **One-hot-encoder**:
  - La longitud del código es igual al número de clases.
  - La clase correcta es denotada con un valor **uno** y el resto es denotado por el valor **cero**.
- **Ejemplo:** supongamos un problema de clasificación de 3-clases.
  - **Clase #1: Gato, Clase#2: Perro Clase #3: León**

$$
\begin{aligned}
Class1 &= [1 \quad 0 \quad 0] \\
Class2 &= [0 \quad 1 \quad 0] \\
Class3 &= [0 \quad 0 \quad 1]
\end{aligned}
$$

Etiquetas Binarias Multi-clases

- **Número de Clases: 2**

$$Class1 = [1 \quad 0]$$
$$Class2 = [0 \quad 1]$$

- **Número de Clases: 3**

$$Class1 = [1 \quad 0 \quad 0]$$
$$Class2 = [0 \quad 1 \quad 0]$$
$$Class3 = [0 \quad 0 \quad 1]$$

- **Número de Clases: 4**

$$Class1 = [1 \quad 0 \quad 0 \quad 0]$$
$$Class2 = [0 \quad 1 \quad 0 \quad 0]$$
$$Class3 = [0 \quad 0 \quad 1 \quad 0]$$
$$Class4 = [0 \quad 0 \quad 0 \quad 1]$$

Observación.:
Las Etiquetas binarias corresponde a una Matriz de Identidad, cuyo dimensión es igual al número de Clases.

Clasificación Multi-clases: Regresión Softmax

- La probabilidad que una muestra dada pertenezca a la clase *k* es modelada por la expresión siguiente:

$$P(T_n = k/x_n, w) = p_k(x_n), \qquad k = 1,2,\cdots,K$$

$p_k(x_n)$: Denota la probabilidad de la clase *k-ésima,* dada la entrada *x*. $\sum_{k=1}^{K} p_k(x_n) = 1$

- Para una entrada dada, el *scrore lineal* de la clase *k-esima* es dado por:

$$z_k = w_{k,1}x_{n,1} + w_{k,2}x_{n,2} + \cdots + w_{k,D}x_{n,D}, \qquad w_k \in \mathcal{R}^D$$

$$z_k = w_{k,0}x_{n,0} + w_{k,1}x_{n,1} + w_{k,2}x_{n,2} + \cdots + w_{k,D}x_{n,D}, \qquad x_{n,0} = 1$$

w_k: Representa el vector de pesos asociado a la clase *k*-ésima.

Clasificación Multi-clases: Regresión Softmax

- La probabilidad de la *k*-ésima clase es estimada usando la función **Softmax**, dada como:

$$p_k(x_n) = f(z_k)$$

- ***Probabilidad k-ésima***

$$f(z_k) = \frac{exp(z_k)}{\sum_{i=1}^{K} exp(z_i)}$$

- ***Softmax***

$$z_k = x_n w_k, \qquad z_k \in \mathcal{R}^K$$

- ***Scores lineal***

Ejemplo: Clasificación Multiclases con Regresión Softmax

- **Considerar un problema de clasificación correspondiente a 3-clases y cada muestra con 2-atributos.**

Valores de entradas: $x=$ 0.3998 0.2599 0.8001

Pesos: $w=$

0.0782	0.9619	0.8173
0.4427	0.0046	0.8687
0.1067	0.7749	0.0844

- ***Solución:***

- ***Scores lineal:*** $z= xw =$ -0.2629 0.5650 -0.8610

- ***Probabilidad de cada clase:*** $p=Softmax(z) =$ 0.2605 0.5962 0.1433

- ***Clase Predicha:***

1. **[Value Position] =max(p)**
2. ***Clase = Position***
3. ***Clase=2***

Training Regresión Softmax usando Descenso Gradiente con Momentum (mGD)

Training Regresión Softmax.

- Considerar un problema de clasificación de *K*-clases, donde cada muestra contiene ***D***-características.
- Asuma un registro de datos correspondiente a ***N***-muestras.
- El ***dataset*** es denota por la siguiente expresión:

$$\{X_n, T_n\}_{n=1}^{N}, \quad X_n \in \Re^D, \qquad T_n \in \{0,1\}^K$$

- X_n : representa la *n*-ésima muestra de training.
- T_n : representa la *n*-ésima clase objetivo de training.
- K : denota el número de clases.

Train Regresión Softmax

- Para estimar los pesos del modelo usaremos el algoritmo **mGD**.

- La Función de Optimización para estimar los pesos es llamada : ***'Entropía Cruzada '*** y es definida como:

$$E = -\frac{1}{N}\sum_{n=1}^{N}\sum_{k=1}^{K} T_{k,n} ln(y_{k,n}), \qquad y_{k,n} = softmax(z_{k,n})$$

- El objetivo es minimizar la función de Entropía Cruzada usando el Gradiente con respecto a los pesos del modelo (***W***).

Train Regresión Softmax: mGD

- Ajuste de pesos ***w*** usando Notación Vectorial :

$$w^{(k)} = w^{(k-1)} - v^{(k)}$$

$$v^{(k)} = \beta \cdot v^{(k-1)} + \mu \frac{\partial E}{\partial w}$$

$$\frac{\partial E}{\partial w} = -\frac{1}{N}(T - Y)X^T$$

$$w^{(0)} = random, \qquad v^{(0)} = zeros\left(w^{(0)}.shape\right)$$

$$k = 1, \dots, MaxIters, \qquad \mu \in (0,1), \qquad \beta = 0.9$$

Training Regresión Softmax usando miniBtach-RMSprop

Training Softmax: MiniBatch-RMSprop

- **Paso #1**: Re-ordenar aleatoriamente la localización de cada muestra de la base datos de training.

- **Paso #2**: Dividir las *N*-muestras de la base de datos en Batch de *M*-muestras.

$$B = \frac{N}{M}$$

B : Número de Batch

- **Paso #3**: Entrenar el modelo Softmax usando un Número Máximo de Épocas.
  - Cada Épocas ajusta los pesos del Softmax ***B***-veces vía el RMSprop.

Ajuste Pesos de Softmax: miniBatach-RMSprop

Entropía Cruzada: $$E = -\frac{1}{M}\sum_{m=1}^{M}\sum_{k=1}^{K}\mathcal{T}_{k,m}log(y_{k,m}), \qquad y_{k,m} = softmax(z_{k,m})$$

- ***M*** : número de muestras, ***K***: numero de clases, $t_{j,n}$: valores deseados (etiquetas/clases)

Ajuste Pesos Softmax: (Notación Matricial)

$$W(t+1) = W(t) - \mu \times gRMSp$$
$$t = 0,1,2,\dots, MaxIter$$
$$\mu \in (0,1)$$

- Para calcular los valores de *gRMSp* debemos obtener previamente el gradiente del Costo con respecto a los pesos *W*. El gradiente de los pesos es denotado por:

$$gW = \frac{\partial E}{\partial W}$$

Ajuste Pesos de Softmax: miniBatach-RMSprop

Ajuste Pesos Softmax:
(Notación Matricial)

$$gRMS = \frac{1}{\sqrt{V(t+1)} + \varepsilon} \otimes gW$$
$$V(t+1) = \beta \times V(t) + (1-\beta) \times (gW)^2$$
$$gW = -\frac{1}{M}(D - Y)X^T$$

Valores Iniciales:

$W(0) =$ random
$V(0) =$ w.shape
$V(0) = 0$
$\beta_1 = 0.9$
$\varepsilon \in \left(10^{-6}, 10^{-10}\right)$

Producto Hadamard: $\oplus$

Métricas de Rendimiento: Clasificación Multi-Clases

$$\text{Precision}(i) = \frac{CM_{i,i}}{\sum_{j=1}^{n_c} CM_{i,j}}, \qquad i = 1, \ldots, n_c$$

$$\text{Re}\,c\,all(j) = \frac{CM_{j,j}}{\sum_{i=1}^{n_c} CM_{i,j}}, \qquad j = 1, \ldots, n_c$$

$$\text{F}-\text{score}(j) = 2 \times \frac{\text{Pr}\,e\,cison(j) \times \text{Re}\,c\,all(j)}{\text{Pr}\,e\,cision(j) + \text{Re}\,c\,all(j)}$$

$$Accuracy = \frac{1}{N} \sum_{i=1}^{n_c} CM_{i,i}$$

Evaluación #2:
Clasificación Multiclase
usando
PCA+RFF
Reg. Softmax +RMSprop

CONTINUARÁ….